Лекция 2
Базы данных и основы SQL

Tinkoff.ru

Оглавление

Откуда берутся данные?

Каждая система в рамках процесса выполняет свою роль и как следствие собирает свои собственные данные. При аналитике может потребоваться обращаться к данным с разных систем, для этого нужно понимать откуда их взять. А для ускорения работы и уменьшения нагрузки на эти системы, лучше их скопировать и положить в хранилище данных.

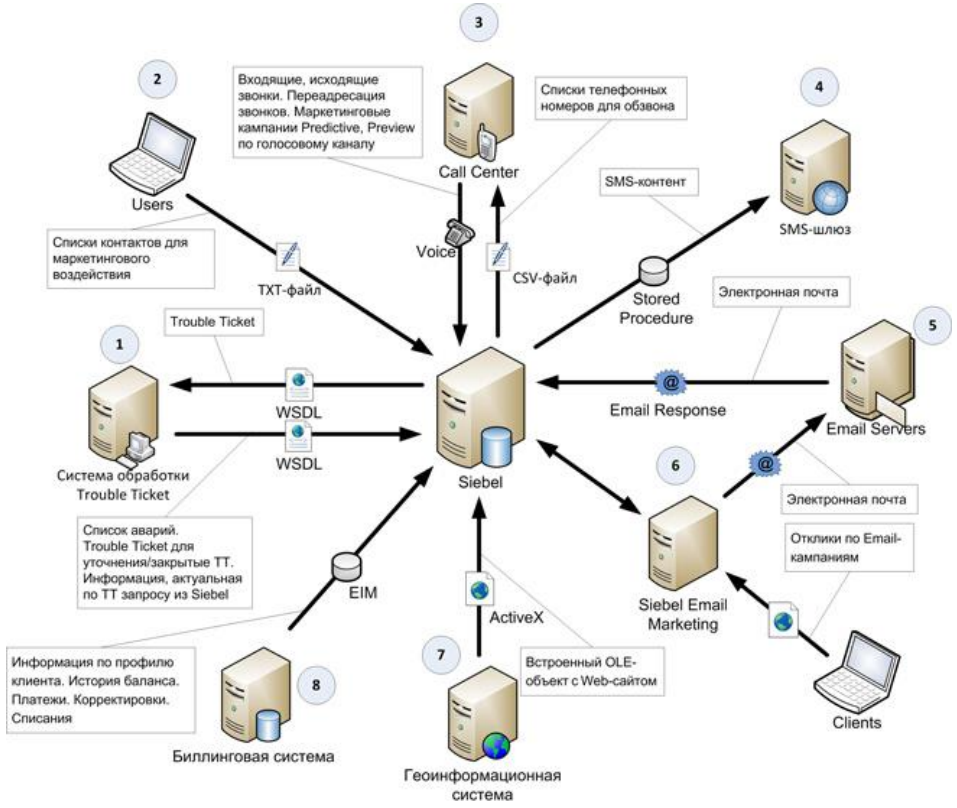

Схема с сайта http://www.tadviser.ru/

Хранение данных

Данные удобно воспринимать в формате таблиц – это достаточно наглядно, так как в рамках процесса зачастую происходят схожие “явления”, просто каждая со своим набором параметров.

Сроки таблицы – они же **записи**, разделяют эти “явления”

Столбцы таблицы – они же **поля**, служат описанием параметров этого “явления”

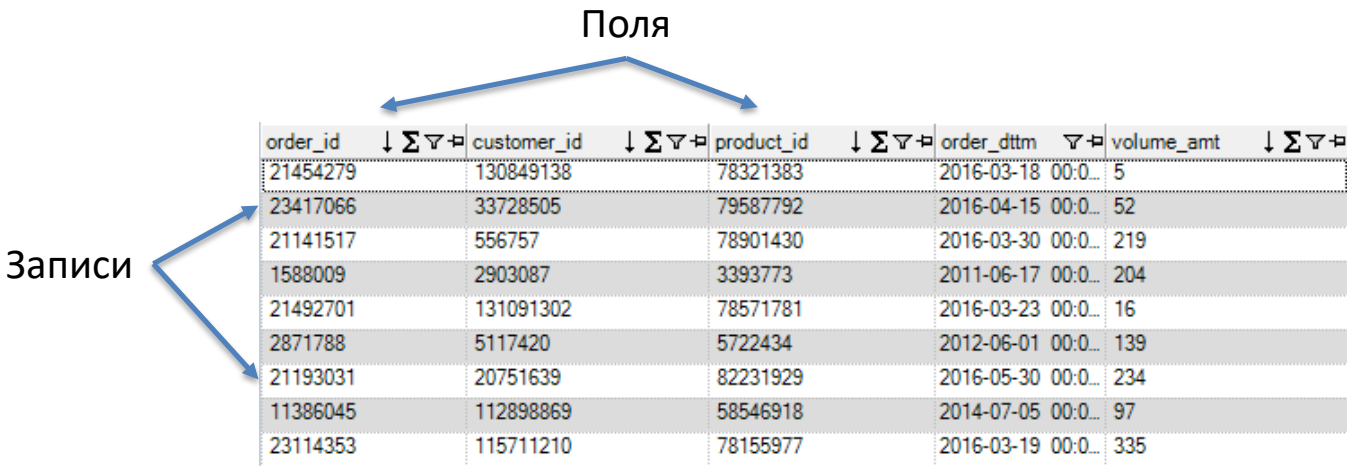

Первичные и вторичные ключи

- Первичный ключ – поле или набор полей, идентифицирующих строку в таблице:
  - недопустимо отсутствие значения;
  - все значения уникальны.
- Внешний ключ – поле или набор полей, устанавливающих связь между данными в двух таблицах. В общем случае не имеет логических ограничений, как первичный ключ.

order_id	customer_id	product_id	order_dttm	volume_amt
21454279	130849138	78321383	2016-03-18 00:0...	5
23417066	33728505	79587792	2016-04-15 00:0...	52
21141517	556757	78901430	2016-03-30 00:0...	219
1588009	2903087	3393773	2011-06-17 00:0...	204
2[illegible]	131[illegible]	78[illegible]	2016-03-23 00:0...	16
2[illegible]	511[illegible]	57[illegible]	2012-06-01 00:0...	139
21193031	20751639	82231929	2016-05-30 00:0...	234
11386045	112898869	58546918	2014-07-05 00:0...	97
23114353	115711210	78155977	2016-03-19 00:0...	335

PK FK FK

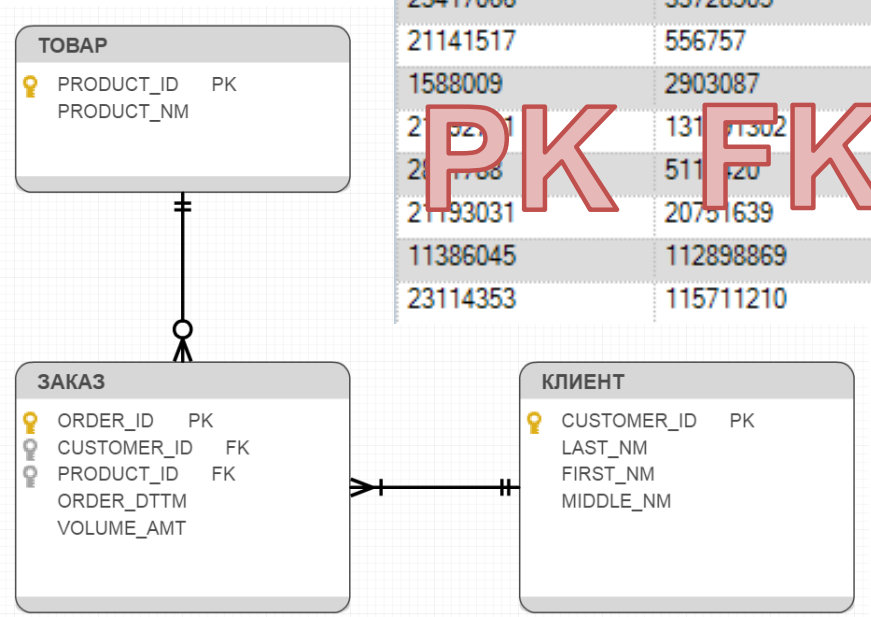

Модель данных

Модель данных - модель «сущность-связь» (ER-модель), описывающая набор взаимосвязанных сущностей, которые отражают потребности бизнеса в аналитике и отчетности.

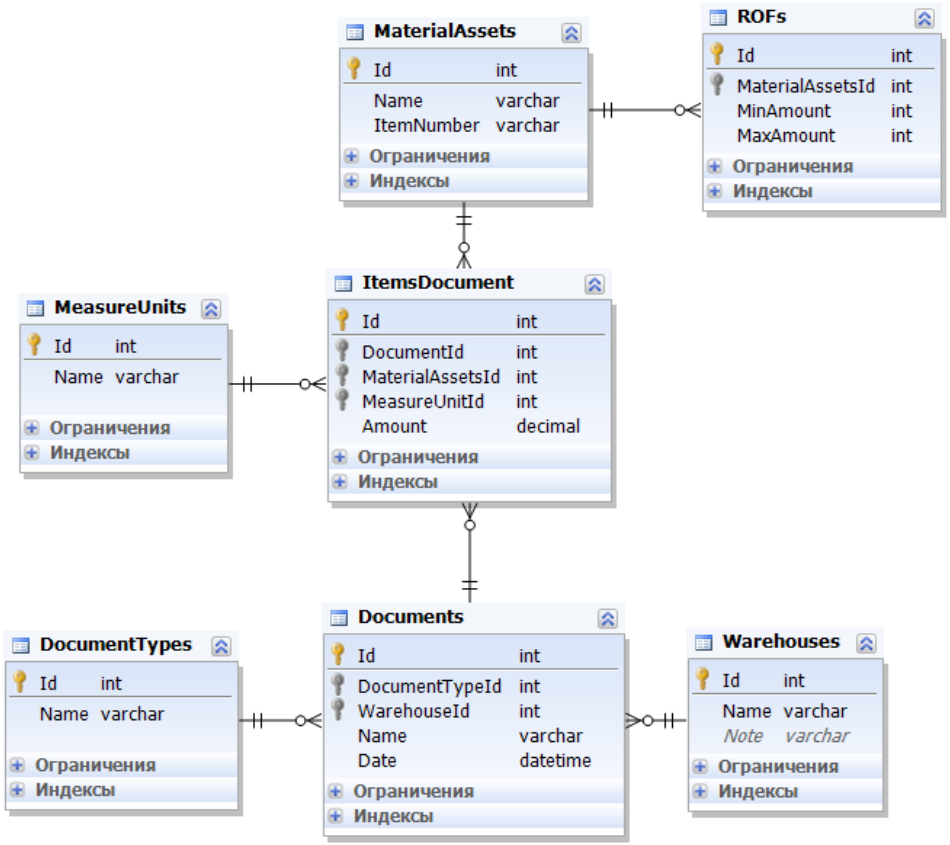

Модель данных

А еще модель данных может выглядеть вот так

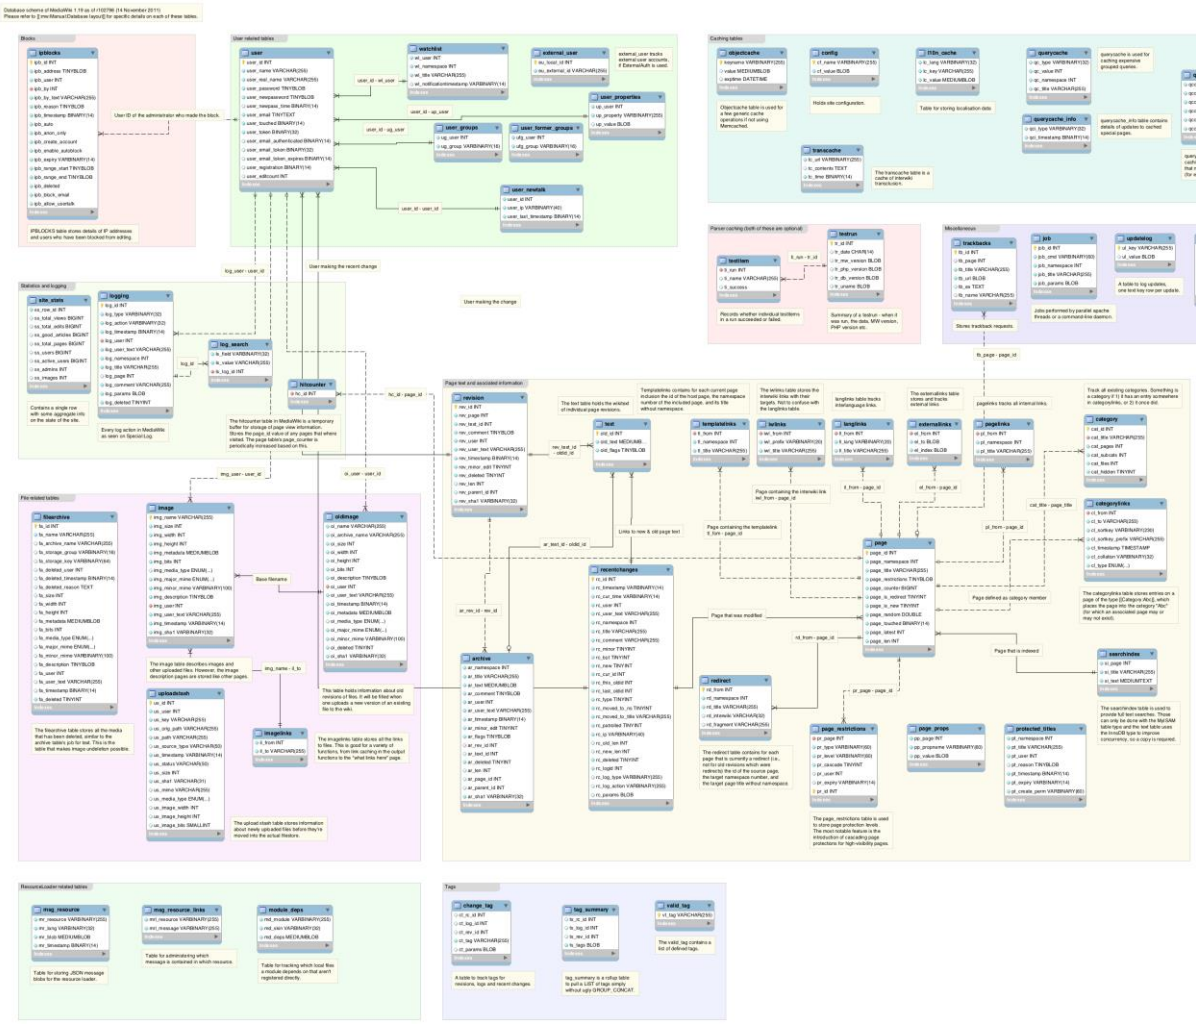

Почти случайные логотипы

Почти случайные логотипы

Почти случайные логотипы

Тинькофф Квест (легенда)

Давайте предположим, что мы запускаем проект Тинькофф Квест. Будем открывать квесты во всей стране по франшизной системе. Помимо этого, мы будем помогать нашим партнерам с легендой квеста и его обустройством, для этого мы заключаем контракты с креативными агентствами. В рамках игры, команде участников будет предложено пройти квест за 50 минут. В ходе прохождения им при необходимости будет помогать оператор. На игру может записаться любой желающий как по предварительной записи через сайт или по телефону, так и непосредственно на локации самого квеста. При бронировании квеста заявитель обязан оставить телефон, чтобы с ним можно было связать в случае форс мажоров и выслать информацию по бронированию. В теории бронь можно и отменить, но в этом случае нам станет очень грустно. Непосредственно перед игрой от участников собираются подписи, что они по своей воле решились поучаствовать в нашем квесте. После чего начинается игра, от которой все герои получают массу впечатлений. Периодически мы запускаем промо акции, они могут быть приурочены к каким-нибудь значимым датам или событиям, а могут родиться спонтанно, только потому что нам так захотелось.

P.S. Данная история целиком и полностью вымышленная, все совпадения с реальными личностями случайны ☺

Тинькофф Квест (часть модели)

У нас модель хранилища данных будет выглядеть вот так (но это не точно)

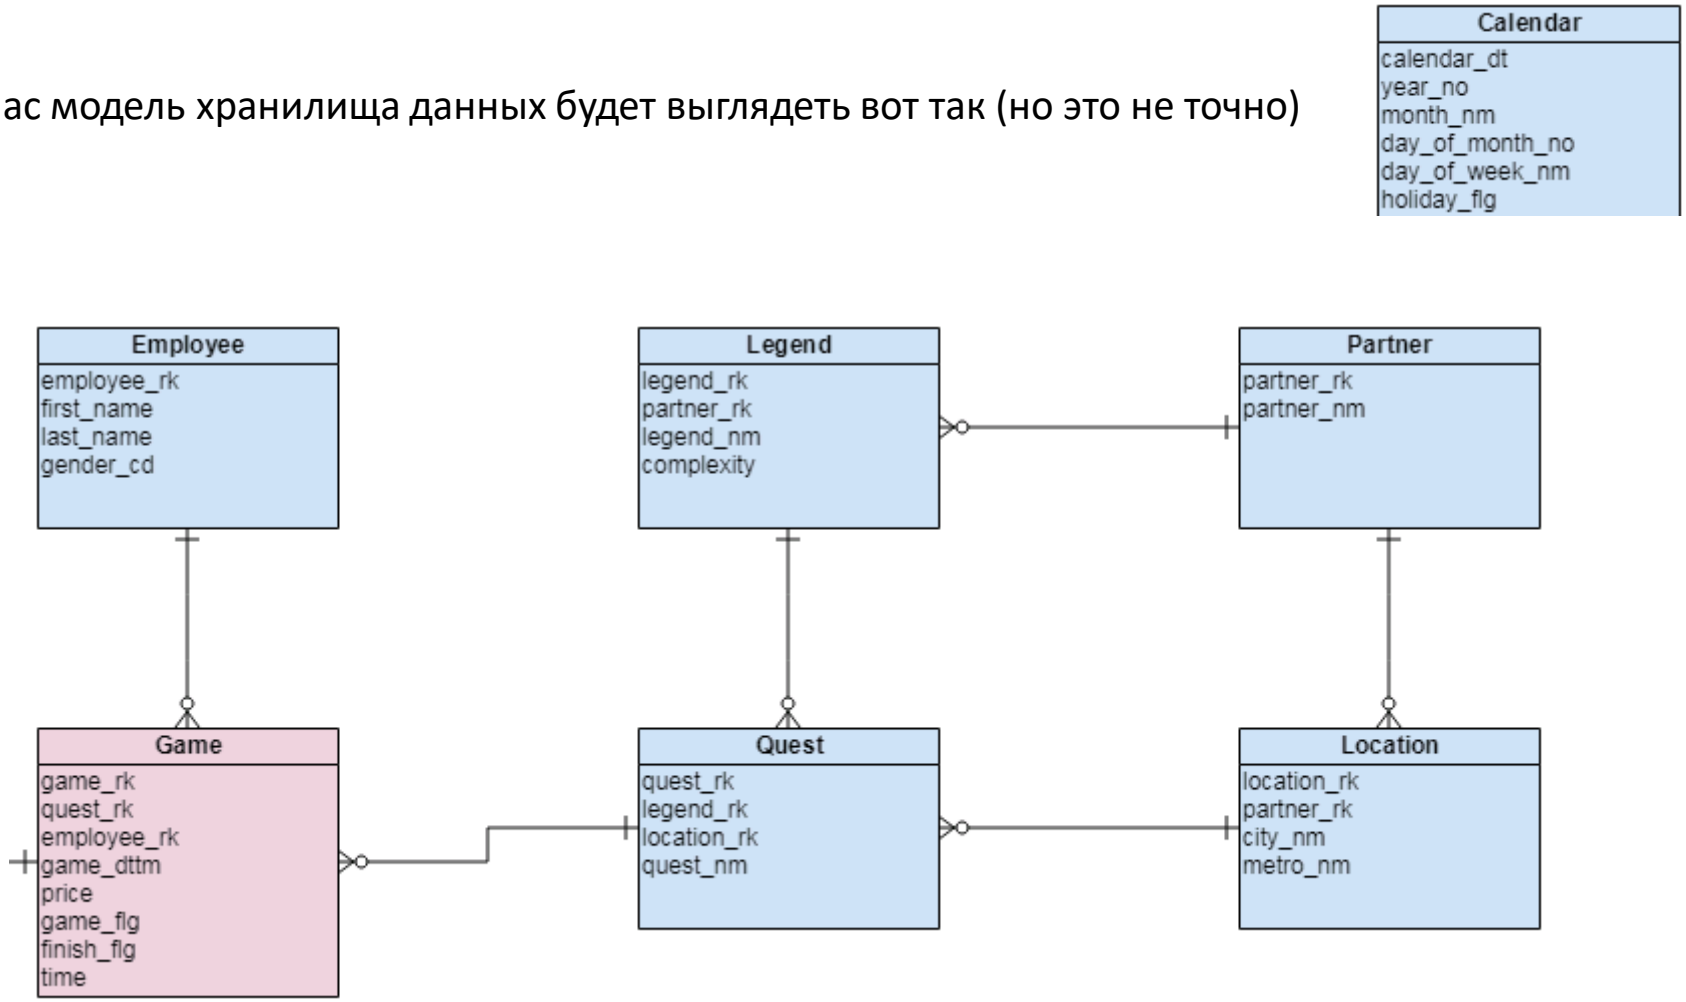

Оглавление

Подключаемся к базе

- Устанавливаем pgAdmin4 https://www.pgadmin.org/download/
- Создаем новое подключение к серверу
- Задаем любое имя на вкладке **General**
- Переходим на вкладку **Connection**
- Хост **82.148.21.106**
- Порт **8432**
- Database **postgres**
- Пользователь **student**
- Пароль **Bahz3loDieta**

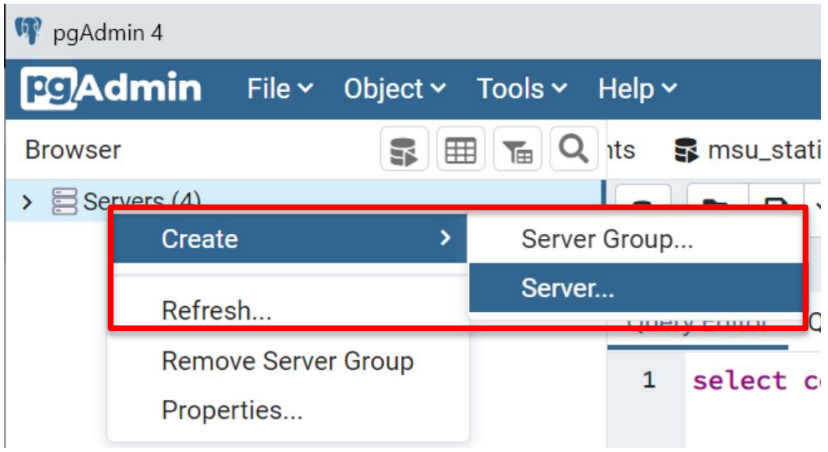

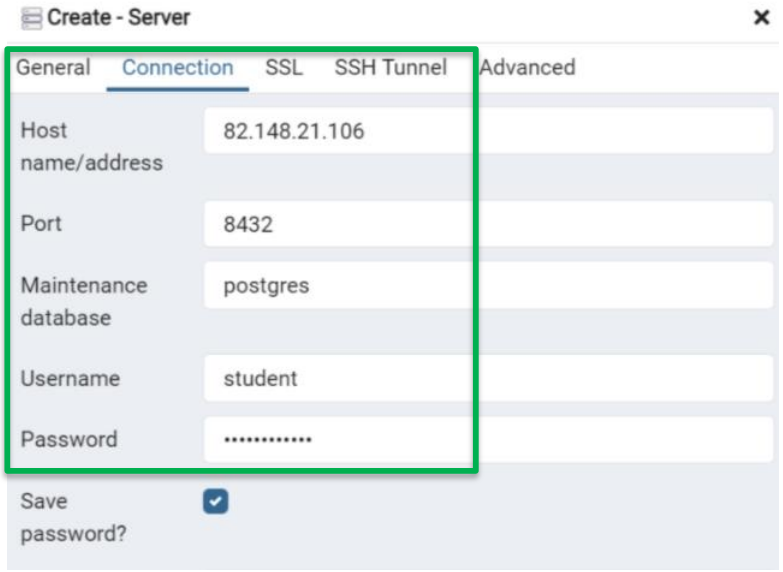

Подключаемся к базе

После этого, у вас будет доступ к данным, которые будут лежать в схеме ***msu_analytics***.
Открываем окно для написания запросов и вперед.

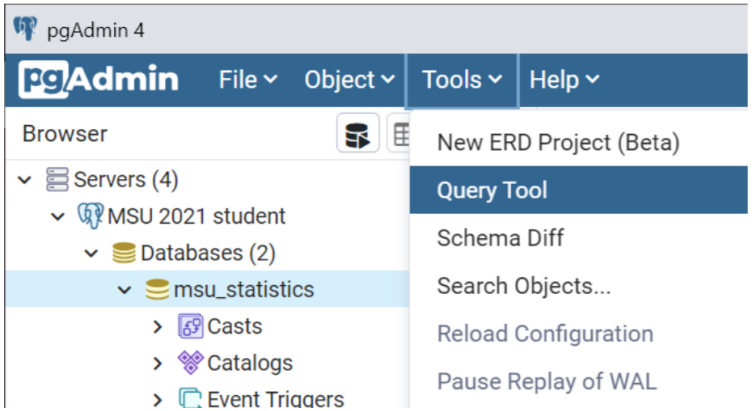

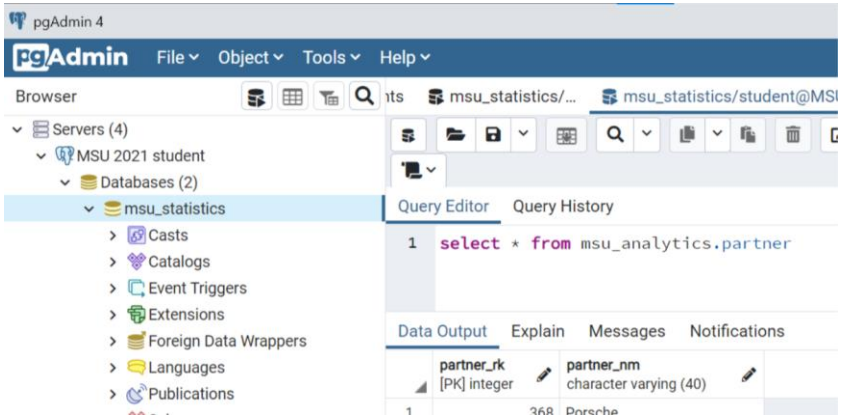

SQL - запрос

Первый закон аналитики: “прежде чем начать анализировать данные, их нужно собрать”.

С этим легко можно справиться при помощи SQL запроса.

Структура SQL запроса проста:

- Select
- From
- Where
- Group by
- Having
- Order by
- Limit

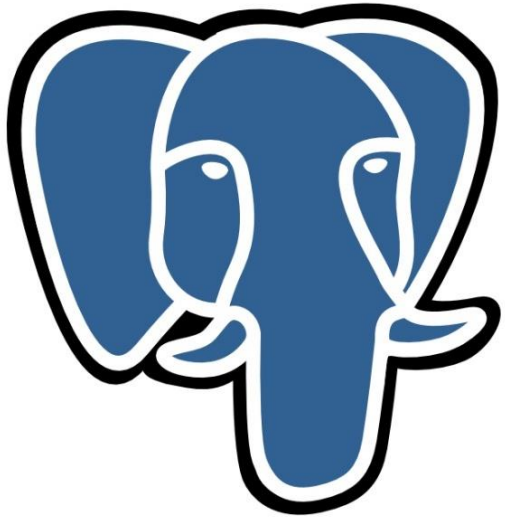

PostgreSQL

Операторы Select и From

Оператор Select отвечает за то, какие поля мы выводим в результат, в то время как оператор From – какие таблицы мы используем. Они должны быть в каждом запросе.

```
Select distinct
    quest_rk
From
    msu_analytics.game
```

```
Select
    *
From
    msu_analytics.employee
```

Если в операторе Select написать “*”, то будут выведены все поля, а если приписать distinct, то из всех одинаковых записей останется только одна.

```
Select
    count(*) as cnt
    ,avg(time) as avg_time
From
    msu_analytics.game
```

Если в операторе Select писать только агрегирующие функции, то он выдаст единственную строку с агрегатом по всей таблице. В данном случае число строк таблицы и среднее значение времени (по тем строкам, где оно заполнено)

Приписка as позволяет поля переименовывать.

Оператор Where

Оператор Where позволяет отфильтровать только нужные записи.

```
Select
        count(*) as cnt
From
        msu_analytics.employee
Where
        gender_cd = ‘f’
```

Теперь мы считаем количество не всех строк, а только тех, в которых *gender_cd = ‘f’*, что в нашем случае значит – посчитать количество девушек сотрудниц

В операторе Where можно использовать любые логические связки с использованием and, or, not

```
Select
        count(*) as cnt
From
        msu_analytics.employee
Where
        gender_cd = ‘m’
        and first_name = ‘Том’
```

Операторы Group by и Having

Оператор Group by позволяет данные группировать

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        gender_cd
```

Теперь в выводе мы увидим не 1 запись как ранее, а 2. Одна будет говорить сколько у нас сотрудников мужчин, а вторая - сколько сотрудниц женщин.

Having – это своего рода фильтрация, но уже после группировки. В данном случае, мы оставим только те записи, в которых значение поля *cnt* будет больше 35.

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        gender_cd
Having
        count(*) > 35
```

Оператор Order by

Оператор Order by отвечает за сортировку выводимого результата

```
Select
        gender_cd
        ,count(*) as cnt
From
        msu_analytics.employee
Group by
        1
Order by
        2 desc
```

Для начала заметим, что в операторе Group by мы использовали число – это порядковый номер поля в операторе Select, то есть сгруппировали мы по полю *gender_cd*.

Сортировка же отработает по второму полю, то есть по полю *cnt*, приписка desc же означает, что сортировка будет произведена в обратном порядке (от большего к меньшему)

В операторах Group by и Order by можно использовать несколько полей, в этом случае их нужно перечислить через запятую.

Join

Join позволяет нам связывать записи из разных таблиц между собой

```
Select
        a.employee_rk
        ,count(*) as cnt
From
        msu_analytics.employee a
        inner join msu_analytics.game b
                on a.employee_rk = b.employee_rk
Group by
        1
Order by
        2 desc
```

Inner join к каждой записи первой таблицы, которую мы обозначили за *a*, подставляет записи из таблицы, которую мы обозначили за *b* подходящие под условия после on, при этом, на 1 запись первой таблицы может прийтись несколько записей из второй, в этом случае создастся запись на каждую комбинацию.

Если на запись из первой таблицы не нашлось записи из второй, то запись первой таблицы отфильтровывается.

Если бы мы использовали left join, то такая запись первой таблицы дополнилась бы пустой строкой из второй таблицы.

Как результат мы получили таблицу, в которой на каждого сотрудника указано на сколько игр он был записан оператором, а результат отсортирован от большего числа игр к меньшему.

Join

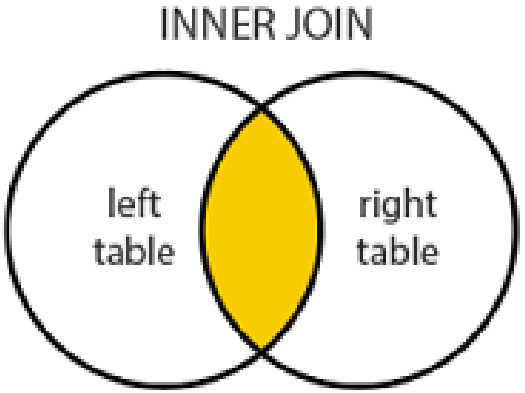
INNER JOIN
left table
right table

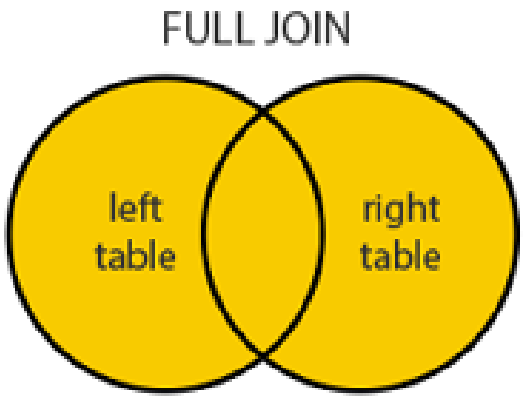
FULL JOIN
left table
right table

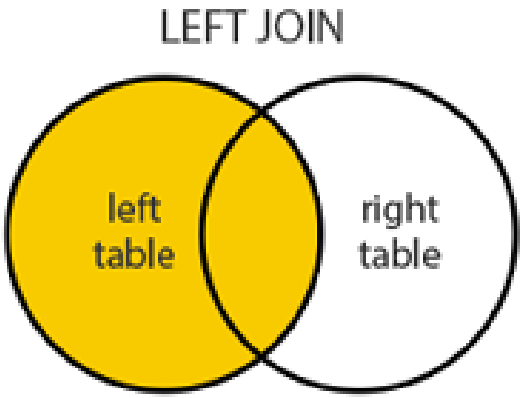
LEFT JOIN
left table
right table

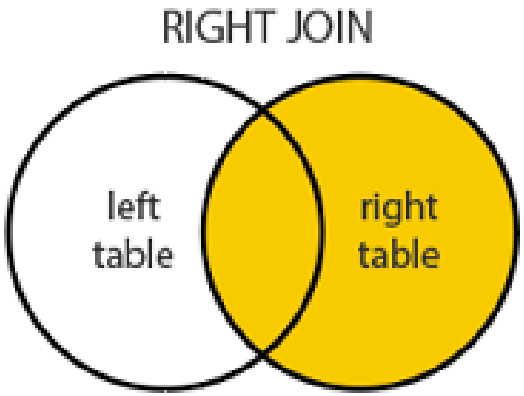
RIGHT JOIN
left table
right table

Join

Можно использовать несколько Join подряд.

```
Select
        a.partner_rk
        ,a.partner_nm
        ,b.partner_nm as b_name
        ,c.partner_nm as c_name
From
        msu_analytics.partner a
        inner join msu_analytics. partner b
                on a.partner_rk = b.cpartner_rk
        left join msu_analytics. partner c
                on a.partner_rk = c.partner_rk
                and c.partner_rk % 2 = 1
```

Подзапросы

Подзапросы позволяют нам “создавать” таблицы и сразу к ним обращаться.

```
Select
        a.*
From
        (
        Select
                *
        From
                msu_analytics.employee
        ) a
```

Сейчас мы написали абсолютно бесполезный запрос, но он работает! Не повторяйте это дома.

По сути, мы сначала целиком скопировали таблицу *msu_analytics.employee*, после чего снова её скопировали и вывели.

По факту, чаще всего подзапросы используются в случае, когда вы хотите использовать не целую таблицу, а какой-то её агрегат.

Промежуточные таблицы

Иногда удобнее создать таблицы иным способом

```
With test_table as
(
        Select *
        From msu_analytics.employee
        Where gender_cd = ‘f’
)

Select *
From test_table
```

Сейчас мы создали таблицу test_table и теперь можем к ней обращаться неограниченное количество раз.

Промежуточные таблицы

Их тоже можно создавать несколько

```
With test_table as
(
        Select *
        From msu_analytics.employee
        Where gender_cd = ‘f’
),
test_table_2 as
(
        Select *
        From msu_analytics.employee
        Where gender_cd = ‘f’
)
Select *
From test_table
```

Пара полезных советов

```
Select *
From msu_analytics.game
Limit 10
```

Limit позволяет выводить только часть результата, пишется он в самом конце

Аккуратно сравнивайте поля в разных форматах.

Особенно это касается даты и даты - времени

Game_dttm <= ‘2018-02-01’ Эквивалентно Game_dttm <= ‘2018-02-01:00:00:00’

Домашнее задание

1) Со сколькими креативными агентствами мы работаем? Креативным агентством считается тот партнер, у которого нет локаций для проведения квестов, но при этом они пишут сценарии, которые мы используем.
2) Выведите название того партнера, на чьих локациях под руководством девушек операторов, среднее время прохождения квеста ниже, чем у всех остальных и укажите это время. В случае неоднозначного ответа, выведите того партнера, у которого название лексикографически меньше. (лексикографически – значит меньше по алфавиту)
3) У какого квеста (выпишите его quest_nm) разница доли состоявшихся квестов в январе и в феврале наибольшая по модулю? Долей считать количество состоявшихся квестов поделить на количество заявленных. В случае наличия нескольких квестов, подходящих под условие, требуется вывести тот, у которого значение quest_rk больше.

Оглавление

Partner

Витрина содержит информацию о наших бизнес партнерах

Название поля	Описание
Partner_rk	Ключ партнера в хранилище данных
Partner_nm	Название партнера

Location

Витрина содержит информацию о тех локациях, на которых проходят квесты нашей франшизы

Название поля	Описание
Location_rk	Ключ локации в хранилище данных
Partner_rk	Ключ партнера, которому принадлежит эта локация
City_nm	Название города, в котором расположена локация
Metro_nm	Название ближайшей станции метро к локации

Legend

Витрина содержит информацию о легендах (сценариях/сюжетах) конкретных квестов.

Название поля	Описание
Legend_rk	Ключ легенды в хранилище данных
Partner_rk	Ключ партнера, которому принадлежит авторское право на эту легенду
Legend_nm	Запатентованное название сюжета
Complexity	Сложность квеста, идущего по данному сюжету

Quest

Витрина содержит информацию о квестах, в которые могут играть наши клиенты.

Название поля	Описание
Quest_rk	Ключ квеста в хранилище данных
Legend_rk	Ключ легенды, в рамках которой играется квест
Location_rk	Ключ локации, на которой квест располагается
Quest_nm	Название квеста

Employee

Витрина содержит информацию о сотрудниках, которые проводят игры и помогают командам.

Название поля	Описание
Employee_rk	Ключ сотрудника в хранилище данных
First_name	Имя сотрудника
Last_name	Фамилия сотрудника
Gender_cd	Пол сотрудника

Game

Витрина с расписанием запланированных и состоявшихся игр (отдельных прохождений и просто слотов в расписании по играм)

Название поля	Описание
Game_rk	Ключ отдельной игры в хранилище данных
Quest_rk	Ключ квест, в рамках которого проходила игра
Employee_rk	Ключ сотрудника, который проводил игру
Game_dttm	Дата-время запланированного начала игры
Price	Стоимость игры
Game_flg	Флаг того, что игра состоялась
Finish_flg	Флаг того, что состоявшуюся игру удалось пройти
Time	Время прохождения игры

Calendar

Витрина с календарем

Название поля	Описание
Calendar_dt	День календаря
Year_no	Год
Month_nm	Название месяца
Day_of_month_no	Номер дня внутри месяца
Day_of_week_nm	Название дня недели
Holiday_flg	Флаг выходного или праздничного дня